

Национальный исследовательский университет
"Высшая школа экономики"

Исследовательский проект
Обучение ретривера на инструкциях
Promptriever: Instruction-Trained Retrievers

Выполнил:

Студент группы БПМИ242
Хасанов Айдар Рифкатович

Научный руководитель:

Андреева Дарья Александровна

Москва, 2026

Содержание

Аннотация	ii
1 Введение	1
1.1 Актуальность	1
1.2 Цели	1
1.3 Задачи проекта	1
2 Обзор и анализ источников	2
2.1 Promptriever	2
2.2 InstructOR	2
2.3 Multilingual-E5	3
2.4 BGE-M3	3
2.5 SberQuAD	3
2.6 mFollowIR	4
2.7 ruMTEB	4
3 Основная часть	4
3.1 Первые эксперименты	4
3.2 Сбор тренировочного датасета	5
3.3 Дообучение модели	6
Список использованных источников	7

Аннотация

Данная работа посвящена реализации подхода Promptriever для русского языка путем дообучения нескольких моделей на модифицированном датасете SberQuAD. Целью исследования является создание поисковой системы, способной эффективно следовать текстовым инструкциям пользователя для повышения точности и управляемости поиска. Эффективность метода оценивается на бенчмарках ruMTEB и mFollowIR с использованием метрик nDCG@10 и pMRR.

1 Введение

Поиск информации прошел путь от простого сопоставления ключевых слов до использования семантических векторов, создаваемых нейронными сетями. Современные би-энкодеры позволяют находить документы по смыслу, переводя запросы и документы в единое векторное пространство $\mathbb{R}^d$. Однако традиционные модели поиска ограничены: они не способны учитывать специфические инструкции пользователя, воспринимая их как часть поискового запроса.

Данная работа посвящена реализации подхода, использованного в статье Promptriever [8] для русского языка. Основная идея заключается в обучении модели воспринимать текстовые инструкции.

1.1 Актуальность

Дообучение ретривера, способного понимать инструкции на русском языке, позволит:

1. Повысить точность поиска в специализированных задачах.
2. Обеспечить управляемость систем поиска за счет инструкций.

1.2 Цели

1. Изучение и реализация модели Promptriever, которая умеет работать с инструкциями на естественном языке при выполнении поиска документов.
2. Оценка эффективности модели в различных условиях.
3. Сравнение различных моделей в качестве baseline при реализации ретривера.

1.3 Задачи проекта

1. Изучение архитектуры, предложенной в статье Promptriever.
2. Подготовка обучающего датасета на основе SberQuAD [3] с генерацией позитивных и негативных инструкций для обучения модели следованию командам.
3. Дообучение модели multilingual-e5-base [6].
4. Оценка качества базового поиска на бенчмарках ruMTEB [4] (RuBQ, RiaNews, MIRACL) по метрике nDCG@10.
5. Оценка способности модели следовать инструкциям на retrieval-бенчмарке mFollowIR [7] с использованием метрики pMRR.
6. Сравнение разных моделей в качестве baseline.

2 Обзор и анализ источников

В основу исследования легли следующие работы:

2.1 Promptriever

Promptriever: Instruction-Trained Retrievers Can Be Prompted Like Language Models [8] — статья, вводящая концепцию обучения ретриверов на инструкциях и демонстрирующая их эффективность в zero-shot задачах. В отличие от обычных би-энкодеров, которые опираются на семантическую близость векторов, Promptriever обучается учитывать условия из промпта. Основные преимущества:

1. Promptriever обучается на данных без фиксированной структуры запросов, что позволяет использовать его в zero-shot режиме на данных различной сложности.
2. Использование негативных примеров (где документ подходит по теме, но нарушает условие инструкции) существенно повышает pMRR (прирост в +14.3 по сравнению с RepLLaMA).
3. Promptriever можно масштабировать. Авторы демонстрируют, что качество следования инструкциям коррелирует с размером базовой модели и объемом синтетических данных, сгенерированных с помощью LLM для обучения.

2.2 InstructOR

One Embedder, Any Task: Instruction-Finetuned Text Embeddings [5] — статья, в которой также используется идея перевода запросов и инструкций в эмбединг. Среди преимуществ Promptriever относительно InstructOR можно выделить:

1. Умение обрабатывать более сложные инструкции. InstructOR обучался на фиксированных инструкциях формата `represent the {domain} for {task type} supporting documents; input: {input}`, в то время как Promptriever может воспринимать любые инструкции.
2. Использует негативные инструкции к запросам при дообучении. Это дает значительный прирост в pMRR, так как модель учится распознавать важные слова в условиях.
3. В целом у Promptriever гораздо лучше качество поиска и следование инструкциям. Средний pMRR на FollowIR датасете составляет +11.2 вместо -2.8 у Instructor XL. На MS-MARCO метрика nDCG у Promptriever также сильно выше: 92.1 против 48.6 [8].

В свою очередь, у Promptriever есть и недостатки относительно подхода InstructOR.

1. Метод, предложенный в InstructOR, отлично обобщается для большего числа задач: от классификации и retrieval до оценки генерации текста.
2. Зависимость от качества генерации инструкций LLM. В InstructOR инструкции были собраны вручную, а не синтетически, что часто дает преимущество.

2.3 Multilingual-E5

Multilingual E5 Text Embeddings [6] — технический отчет по базовой модели данного исследования (multilingual-e5-base), описывающий архитектуру и обучение на мультязычных парах текстов. Особенности модели:

1. Сначала модель проходит контрастивное предобучение на 10^9 парах вида текст-текст из открытых источников, а затем дообучается на $1.6 \cdot 10^6$ текстах и $5 \cdot 10^5$ инструкциях, сгенерированных GPT-3.5/4.
2. E5 был обучен на данных формата `query: {query}, passage: {passage}`. Это нужно будет учитывать при дообучении и тестировании.
3. Модель поддерживает 93 языка.
4. Количество параметров модели — 278M.

2.4 BGE-M3

M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation [2] — многофункциональная мультязычная модель нового поколения. Модель M3 мультязычная и поддерживает более 100 языков, включая русский. Некоторые особенности модели:

1. Кроме обычного режима (dense retrieval), в котором мы сравниваем векторы по косинусной близости, доступны еще 2: multi-vector retrieval и sparse retrieval.
2. BGE-M3, в отличие от M-E5, не требует дополнительного форматирования данных вида `query: {query}`.
3. Имеет большое контекстное окно. Поддержка до 8192 токенов позволяет использовать BGE-M3 для поиска по длинным документам без разбиения на куски.
4. Количество параметров модели — 569M.

2.5 SberQuAD

SberQuAD: Russian Reading Comprehension Dataset: Description and Analysis [3] — русскоязычный аналог датасета SQuAD. Представляет из себя описание и анализ первого крупного датасета для задачи смыслового чтения на русском языке, который используется в данной работе как база для обучения. Датасет содержит более $5 \cdot 10^4$ троек (контекст, вопрос, ответ), собранных с помощью краудсорсинга на базе статей Википедии.

2.6 mFollowIR

mFollowIR: a Multilingual Benchmark for Instruction Following in Retrieval [7] — современный бенчмарк для оценки способности ретриверов следовать инструкциям на разных языках, включая русский. Он включает в себя:

1. Запросы с дополнительными условиями. Например, поиск информации с ограничением по временному интервалу, стилистике или специфическому подмножеству сущностей.
2. Метрику pMRR. Данная метрика штрафует модель, если в топ выдачи попадает документ, релевантный теме, но нарушающий инструкцию. Если модель выдает высокий nDCG, но низкий pMRR, то она не следует инструкциям.

2.7 ruMTEB

The Russian-focused embedders’ exploration: ruMTEB benchmark and Russian embedding model design [4] — работа, представляющая русскоязычное расширение глобального бенчмарка MTEB. Авторы объединили 23 датасета, разделенных на 7 категорий задач (классификация, кластеризация, поиск и др.). Для retrieval задач бенчмарк предлагает проверку на таких наборах данных, как RuBQ, RiaNews и русскоязычную версию MIRACL.

3 Основная часть

3.1 Первые эксперименты

На начальном этапе работы была проведена оценка моделей multilingual-e5-base и bge-m3 без дообучения на инструкциях. Тестирование проводилось на датасете RuBQRetrieval (часть бенчмарка ruMTEB) и mFollowIR.

Таблица 1: Результаты тестирования без дообучения

Модель	RuBQRetrieval (nDCG@10)	mFollowIR (pMRR)
multilingual-e5-base ¹	0.69170	−2.994
bge-m3	0.71178	−2.154

Как видно из таблицы, без дообучения модели показывают неплохие результаты по метрике nDCG, но достаточно слабые результаты по метрике pMRR. Дальнейшие эксперименты будут направлены на обучение модели таким образом, чтобы при сохранении высокого качества поиска она демонстрировала значительный прирост по метрике pMRR.

¹При тестировании использовался формат `query`: {запрос} и `passage`: {текст}

3.2 Сбор тренировочного датасета

За основу датасета для дообучения на инструктивных негативах берется SberQuAD. Для каждого примера (контекст, вопрос, ответ) генерируются позитивные и негативные инструкции. Позитивные инструкции формулируются так, чтобы модель должна была выдавать релевантные документы, а негативные инструкции содержат условия, которые нарушают релевантность.

Инструкции генерировались синтетически с помощью LLM. В качестве генератора использовалась Llama3-8b [1].

Промпт для генерации позитивных инструкций

Ты помогаешь строить обучающий датасет для instruction-following retrieval. По паре вопрос-контекст нужно придумать ОДНУ позитивную инструкцию на русском языке. Позитивная инструкция должна:

1. звучать как реальная поисковая инструкция;
2. быть тематически близкой к вопросу;
3. делать данный контекст ПОДХОДЯЩИМ и релевантным;
4. не должна зависеть от скрытой разметки;
5. не должна быть бессмысленной, слишком общей или противоречивой.

Верни JSON с полями: `positive_instruction`, `relevance_reason`.

Промпт для генерации инструктивных негативов

Ты помогаешь строить instruction-following retrieval датасет по рецепту Promptriever. Для каждого примера нужно создать passages, которые позволяют обучать bi-encoder учитывать инструкцию на уровне конкретного запроса.

Верни JSON со следующими полями:

1. `generated_positive_passage`: passage, релевантный и вопросу, и инструкции
2. `instruction_negative_passages`: список из нескольких passages, которые релевантны исходному вопросу, но НЕ удовлетворяют дополнительному условию инструкции

Требования:

1. passages должны быть правдоподобными и естественными;
2. нельзя делать negative явно абсурдным или нерелевантным теме;
3. negative должен отвечать базовому вопросу, но не проходить по instruction;
4. верни только JSON без markdown.

Разберем генерацию датасета по шагам. По паре (`query`, `context`), где `context` – отрывок из текста (взятый из исходного датасета SberQuAD), `query` – вопрос (также взятый из SberQuAD), строилась пара (`query` + `instruction`, `context`), `instruction` – сгенерированная инструкция.

Затем генерировался текст, который делал `context` релевантным для `query` + `instruction`

(в статье такой текст называют `instruction positive`). И таким же образом 3 текста, которые подходят под `query`, но не подходят под `instruction` (в статье такие называют `instruction negative`).

После этого к каждому `query` искали 2 текста из исходного датасета, которые близки по косинусному расстоянию, но не подходят по смыслу (в статье такие называют `hard negative`). Все эти тексты добавляются в датасет.

3.3 Дообучение модели

При дообучении используется косинусная функция потерь. Ее смысл заключается в том, что близкие векторы по смыслу имеют большое скалярное произведение, а далекие – маленькое. Для пары с позитивной инструкцией (релевантная) мы хотим, чтобы скалярное произведение было как можно больше, а для пары с негативной инструкцией (нерелевантная), наоборот – как можно меньше.

В качестве оптимизатора использовался AdamW со стандартными параметрами и $\text{lr} = 10^{-4}$. На тренировочном датасете `batch_size = 32`.

Список использованных источников

- [1] AI@Meta. “Llama 3 Model Card”. В: (2024). URL: https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md.
- [2] Jianlv Chen и др. *M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. 2025. arXiv: 2402.03216 [cs.CL]. URL: <https://arxiv.org/abs/2402.03216>.
- [3] Pavel Efimov и др. “SberQuAD – Russian Reading Comprehension Dataset: Description and Analysis”. В: *Experimental IR Meets Multilinguality, Multimodality, and Interaction*. Springer International Publishing, 2020, с. 3–15. DOI: 10.1007/978-3-030-58219-7_1.
- [4] Artem Snegirev и др. *The Russian-focused embedders’ exploration: ruMTEB benchmark and Russian embedding model design*. 2025. arXiv: 2408.12503 [cs.CL]. URL: <https://arxiv.org/abs/2408.12503>.
- [5] Hongjin Su и др. *One Embedder, Any Task: Instruction-Finetuned Text Embeddings*. 2023. arXiv: 2212.09741 [cs.CL]. URL: <https://arxiv.org/abs/2212.09741>.
- [6] Liang Wang и др. “Multilingual E5 Text Embeddings: A Technical Report”. В: *arXiv preprint arXiv:2402.05672* (2024).
- [7] Orion Weller и др. *mFollowIR: a Multilingual Benchmark for Instruction Following in Retrieval*. 2025. arXiv: 2501.19264 [cs.IR]. URL: <https://arxiv.org/abs/2501.19264>.
- [8] Orion Weller и др. “Promptriever: Instruction-Trained Retrievers Can Be Prompted Like Language Models”. В: (2024). arXiv: 2409.11136 [cs.IR]. URL: <https://arxiv.org/abs/2409.11136>.