

Национальный исследовательский университет
"Высшая школа экономики"

Исследовательский проект
Обучение ретривера на инструкциях
Promptriever: Instruction-Trained Retrievers

Выполнил:

Студент группы БПМИ242
Хасанов Айдар Рифкатович

Научный руководитель:

Андреева Дарья Александровна

Москва, 2026

Содержание

Аннотация	ii
1 Введение	1
1.1 Актуальность	1
1.2 Цели	1
1.3 Задачи проекта	1
2 Обзор и анализ источников	2
2.1 Promptriever	2
2.2 InstructOR	2
2.3 Multilingual-E5	3
2.4 BGE-M3	3
2.5 SberQuAD	4
2.6 mFollowIR	4
2.7 ruMTEB	4
3 Основная часть	4
3.1 Первые эксперименты	4
3.2 Сбор тренировочного датасета	5
3.3 Дообучение модели	7
Список использованных источников	8

Аннотация

Данная работа посвящена реализации подхода Promptriever для русского языка путем дообучения нескольких моделей на модифицированном датасете SberQuAD. Целью исследования является создание поисковой системы, способной эффективно следовать текстовым инструкциям пользователя для повышения точности и управляемости поиска. Эффективность метода оценивается на бенчмарках ruMTEB и mFollowIR с использованием метрик nDCG@10 и pMRR.

1 Введение

Поиск информации прошел путь от простого сопоставления ключевых слов до использования семантических векторов, создаваемых нейронными сетями. Современные би-энкодеры позволяют находить документы по смыслу, переводя запросы и документы в единое векторное пространство $\mathbb{R}^d$. Однако традиционные модели поиска ограничены: они не способны учитывать специфические инструкции пользователя, воспринимая их как часть поискового запроса.

Данная работа посвящена реализации подхода, использованного в статье Promptriever [8] для русского языка. Основная идея заключается в обучении модели воспринимать текстовые инструкции.

1.1 Актуальность

В последние годы методы информационного поиска претерпели значительную трансформацию благодаря внедрению плотных векторных представлений на базе предобученных языковых моделей. Несмотря на высокую эффективность в классических задачах поиска по сходству, современные ретриверы обладают существенным ограничением: они воспринимают поисковый запрос как единый семантический вектор, игнорируя специфические инструкции пользователя.

В реальных сценариях запросы часто содержат не только описание темы, но и дополнительные ограничения. Обычные би-энкодеры, такие как multilingual-e5, зачастую не способны отличить релевантный документ от документа, который близок по теме, но нарушает заданную инструкцию. Это явление ограничивает гибкость поисковых систем, делая их нечувствительными к контексту задачи.

Актуальность данной работы обусловлена необходимостью разработки и имплементации подходов, которые позволяют адаптировать ретриверы к следованию инструкциям. Это критически важно для создания интеллектуальных ассистентов и систем RAG (Retrieval-Augmented Generation), где точность следования промпту напрямую определяет качество итогового ответа системы.

1.2 Цели

1. Изучение и реализация модели Promptriever, которая умеет работать с инструкциями на естественном языке при выполнении поиска документов.
2. Оценка эффективности модели в различных условиях.
3. Сравнение различных моделей в качестве baseline при реализации ретривера.

1.3 Задачи проекта

1. Изучение архитектуры, предложенной в статье Promptriever.

2. Подготовка обучающего датасета на основе SberQuAD [3] с генерацией позитивных и негативных инструкций для обучения модели следованию командам.
3. Дообучение multilingual-e5-base [6] и других би-энкодеров.
4. Оценка качества базового поиска на бенчмарках ruMTEB [4] (RuBQ, RiaNews, MIRACL) по метрике nDCG@10.
5. Оценка способности модели следовать инструкциям на retrieval-бенчмарке mFollowIR [7] с использованием метрики pMRR.
6. Сравнение разных моделей в качестве baseline.

2 Обзор и анализ источников

В основу исследования легли следующие работы:

2.1 Promptriever

Promptriever: Instruction-Trained Retrievers Can Be Prompted Like Language Models [8] — статья, вводящая концепцию обучения ретриверов на инструкциях и демонстрирующая их эффективность в zero-shot задачах. В отличие от обычных би-энкодеров, которые опираются на семантическую близость векторов, Promptriever обучается учитывать условия из промпта. Основные преимущества:

1. Promptriever обучается на данных без фиксированной структуры запросов, что позволяет использовать его в zero-shot режиме на данных различной сложности.
2. Использование негативных примеров (где документ подходит по теме, но нарушает условие инструкции) существенно повышает pMRR (прирост в +14.3 по сравнению с RepLLaMA).
3. Promptriever можно масштабировать. Авторы демонстрируют, что качество следования инструкциям коррелирует с размером базовой модели и объемом синтетических данных, сгенерированных с помощью LLM для обучения.

2.2 InstructOR

One Embedder, Any Task: Instruction-Finetuned Text Embeddings [5] — статья, в которой также используется идея перевода запросов и инструкций в эмбединг. Среди преимуществ Promptriever относительно InstructOR можно выделить:

1. Умение обрабатывать более сложные инструкции. InstructOR обучался на фиксированных инструкциях формата `represent the {domain} for {task type} supporting documents; input: {input}`, в то время как Promptriever может воспринимать любые инструкции.

2. Использует негативные инструкции к запросам при дообучении. Это дает значительный прирост в pMRR, так как модель учится распознавать важные слова в условиях.
3. В целом у Promptriever гораздо лучше качество поиска и следование инструкциям. Средний pMRR на FollowIR датасете составляет +11.2 вместо -2.8 у Instructor XL. На MS-MARCO метрика nDCG у Promptriever также сильно выше: 92.1 против 48.6 [8].

В свою очередь, у Promptriever есть и недостатки относительно подхода InstructOR.

1. Метод, предложенный в InstructOR, отлично обобщается для большего числа задач: от классификации и retrieval до оценки генерации текста.
2. Зависимость от качества генерации инструкций LLM. В InstructOR инструкции были собраны вручную, а не синтетически, что часто дает преимущество.

2.3 Multilingual-E5

Multilingual E5 Text Embeddings [6] — технический отчет по базовой модели данного исследования (multilingual-e5-base), описывающий архитектуру и обучение на мультиязычных парах текстов. Особенности модели:

1. Сначала модель проходит контрастивное предобучение на 10^9 парах вида текст-текст из открытых источников, а затем дообучается на $1.6 \cdot 10^6$ текстах и $5 \cdot 10^5$ инструкциях, сгенерированных GPT-3.5/4.
2. E5 был обучен на данных формата `query: {query}, passage: {passage}`. Это нужно будет учитывать при дообучении и тестировании.
3. Модель поддерживает 93 языка.
4. Количество параметров модели — 278M.

2.4 BGE-M3

M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation [2] — многофункциональная мультиязычная модель нового поколения. Модель M3 мультиязычная и поддерживает более 100 языков, включая русский. Некоторые особенности модели:

1. Кроме обычного режима (dense retrieval), в котором мы сравниваем векторы по косинусной близости, доступны еще 2: multi-vector retrieval и sparse retrieval.
2. BGE-M3, в отличие от M-E5, не требует дополнительного форматирования данных вида `query: {query}`.
3. Имеет большое контекстное окно. Поддержка до 8192 токенов позволяет использовать BGE-M3 для поиска по длинным документам без разбиения на куски.
4. Количество параметров модели — 569M.

2.5 SberQuAD

SberQuAD: Russian Reading Comprehension Dataset: Description and Analysis [3] — русскоязычный аналог датасета SQuAD. Представляет из себя описание и анализ первого крупного датасета для задачи смыслового чтения на русском языке, который используется в данной работе как база для обучения. Датасет содержит более $5 \cdot 10^4$ троек (контекст, вопрос, ответ), собранных с помощью краудсорсинга на базе статей Википедии.

2.6 mFollowIR

mFollowIR: a Multilingual Benchmark for Instruction Following in Retrieval [7] — современный бенчмарк для оценки способности ретриверов следовать инструкциям на разных языках, включая русский. Он включает в себя:

1. Запросы с дополнительными условиями. Например, поиск информации с ограничением по временному интервалу, стилистике или специфическому подмножеству сущностей.
2. Метрику pMRR. Данная метрика штрафует модель, если в топ выдачи попадает документ, релевантный теме, но нарушающий инструкцию. Если модель выдает высокий nDCG, но низкий pMRR, то она не следует инструкциям.

2.7 ruMTEB

The Russian-focused embedders’ exploration: ruMTEB benchmark and Russian embedding model design [4] — работа, представляющая русскоязычное расширение глобального бенчмарка MTEB. Авторы объединили 23 датасета, разделенных на 7 категорий задач (классификация, кластеризация, поиск и др.). Для retrieval задач бенчмарк предлагает проверку на таких наборах данных, как RuBQ, RiaNews и русскоязычную версию MIRACL.

3 Основная часть

3.1 Первые эксперименты

На начальном этапе работы была проведена оценка моделей multilingual-e5-base и bge-m3 без дообучения на инструкциях. Тестирование проводилось на датасете RuBQRetrieval (часть бенчмарка ruMTEB) и mFollowIR.

Таблица 1: Результаты тестирования без дообучения

Модель	RuBQRetrieval (nDCG@10)	mFollowIR (pMRR)
multilingual-e5-base ¹	0.69170	−2.994
bge-m3	0.71178	−2.154

¹При тестировании использовался формат `query: {запрос}` и `passage: {текст}`

Как видно из таблицы, без дообучения модели показывают неплохие результаты по метрике nDCG, но достаточно слабые результаты по метрике pMRR. Дальнейшие эксперименты будут направлены на обучение модели таким образом, чтобы при сохранении высокого качества поиска она демонстрировала значительный прирост по метрике pMRR.

3.2 Сбор тренировочного датасета

За основу датасета для дообучения на инструктивных негативах берется SberQuAD. Для каждого примера (контекст, вопрос, ответ) генерируются позитивные и негативные инструкции. Позитивные инструкции формулируются так, чтобы модель должна была выдавать релевантные документы, а негативные инструкции содержат условия, которые нарушают релевантность.

Инструкции генерировались синтетически с помощью LLM. В качестве генератора использовалась Llama3-8b [1].

Разберем генерацию датасета по шагам. По паре (`query`, `context`), где `context` – отрывок из текста (взятый из исходного датасета SberQuAD), `query` – вопрос (также взятый из SberQuAD), строилась пара (`query` + `instruction`, `context`), `instruction` – сгенерированная инструкция.

Промпт для генерации позитивных инструкций

Ты помогаешь строить обучающий датасет для instruction-following retrieval. По паре вопрос-контекст нужно придумать ОДНУ позитивную инструкцию на русском языке. Позитивная инструкция должна:

1. звучать как реальная поисковая инструкция;
2. быть тематически близкой к вопросу;
3. делать данный контекст ПОДХОДЯЩИМ и релевантным;
4. не должна зависеть от скрытой разметки;
5. не должна быть бессмысленной, слишком общей или противоречивой.

Верни JSON с полями: `positive_instruction`, `relevance_reason`.

Затем генерировался текст, который делал `context` релевантным для `query` + `instruction` (в статье такой текст называют `instruction positive`). И таким же образом 3 текста, которые подходят под `query`, но не подходят под `instruction` (в статье такие называют `instruction negative`).

Промпт для генерации инструктивных негативов

Ты помогаешь строить instruction-following retrieval датасет по рецепту Promptriever. Для каждого примера нужно создать passages, которые позволяют обучать bi-encoder учитывать инструкцию на уровне конкретного запроса.

Верни JSON со следующими полями:

1. **generated_positive_passage:** passage, релевантный и вопросу, и инструкции
2. **instruction_negative_passages:** список из нескольких passages, которые релевантны исходному вопросу, но НЕ удовлетворяют дополнительному условию инструкции

Требования:

1. passages должны быть правдоподобными и естественными;
2. нельзя делать negative явно абсурдным или нерелевантным теме;
3. negative должен отвечать базовому вопросу, но не проходить по instruction;
4. верни только JSON без markdown.

После этого к каждому **query** искали 2 текста из исходного датасета, которые близки по косинусному расстоянию, но не подходят по смыслу (в статье такие называют *hard negative*). Все эти тексты добавляются в датасет.

Валидация сгенерированных текстов

После генерации текстов, их нужно валидировать, потому что LLM могла сгенерировать текст, который не будет релевантен запросу с инструкцией, хотя должен быть (или наоборот). Для валидации мы используем *bge-reranker-m3-v2* [2]. Каждому тексту и запросу (возможно, с инструкцией) сопоставляет скор – меру сходства. Инструкции и сгенерированные запросы с низким скором отбрасываются.

Таблица 2: thresholds для сгенерированных текстов / инструкций

Инструкция	Instruction positive текст	Instruction negative текст
≥ 1.0	≥ 3.0	≤ 4.0

К первым 5745 строкам из SberQuAD были сгенерированы позитивные инструкции, 5062 из них были помечены как релевантные. После валидации *instruction positive* текстов (для каждого запроса генерировалось по 3 текста) 5219 были отмечены как релевантные. После валидации *instruction negative* 4193 текста были отмечены как релевантные.

Итоговый размер датасета – 1748 строк. В каждой из них было ≥ 1 *hard negatives*, ≤ 3 *instruction negatives* и 1 *instruction positive* текст.

Пример из обучающего датасета

Query: Шедеврами какой музыки признаны сочинения Моцарта?

Instruction: Найдите информацию о музыкальных жанрах, в которых признаны шедевры Моцарта.

Positive: Моцарт - один из наиболее значительных композиторов Венской классической

школы, и его сочинения признаны шедеврами в различных музыкальных жанрах, включая симфоническую, концертную, камерную, оперную и хоровую музыку.

Instruction Negative: В музыке Моцарта можно услышать влияние классицизма и барокко...

Hard Negative: Отличительной чертой творчества Моцарта является сочетание строгих, ясных форм...

3.3 Дообучение модели

Дообучение модели производилось с помощью LoRA. Было проведено несколько экспериментов с разными моделями и разными параметрами LoRA. В качестве loss-функции использовалась MultipleNegativesRankingLoss. Каждая модель дообучалась ровно 20 эпох.

Таблица 3: Результаты дообучения модели multilingual-e5-base с различными параметрами LoRA

r	α	Batch size	Trainable params ¹	RuBQ (nDCG@10)	mFollowIR (pMRR)
16	32	16	0.32%	—	0.61896

После первых экспериментов с дообучением получили прирост в +3.6 по метрике pMRR относительно baseline решения. Это подтверждает гипотезу, что модель научилась различать некоторые дополнительные инструкции в запросах и менять эмбединг в зависимости от них.

¹Доля от всех параметров модели

Список использованных источников

- [1] AI@Meta. “Llama 3 Model Card”. В: (2024). URL: https://github.com/meta-llama/llama3/blob/main/MODEL_CARD.md.
- [2] Jianlv Chen и др. *M3-Embedding: Multi-Linguality, Multi-Functionality, Multi-Granularity Text Embeddings Through Self-Knowledge Distillation*. 2025. arXiv: 2402.03216 [cs.CL]. URL: <https://arxiv.org/abs/2402.03216>.
- [3] Pavel Efimov и др. “SberQuAD – Russian Reading Comprehension Dataset: Description and Analysis”. В: *Experimental IR Meets Multilinguality, Multimodality, and Interaction*. Springer International Publishing, 2020, с. 3–15. DOI: 10.1007/978-3-030-58219-7_1.
- [4] Artem Snegirev и др. *The Russian-focused embedders’ exploration: ruMTEB benchmark and Russian embedding model design*. 2025. arXiv: 2408.12503 [cs.CL]. URL: <https://arxiv.org/abs/2408.12503>.
- [5] Hongjin Su и др. *One Embedder, Any Task: Instruction-Finetuned Text Embeddings*. 2023. arXiv: 2212.09741 [cs.CL]. URL: <https://arxiv.org/abs/2212.09741>.
- [6] Liang Wang и др. “Multilingual E5 Text Embeddings: A Technical Report”. В: *arXiv preprint arXiv:2402.05672* (2024).
- [7] Orion Weller и др. *mFollowIR: a Multilingual Benchmark for Instruction Following in Retrieval*. 2025. arXiv: 2501.19264 [cs.IR]. URL: <https://arxiv.org/abs/2501.19264>.
- [8] Orion Weller и др. “Promptriever: Instruction-Trained Retrievers Can Be Prompted Like Language Models”. В: (2024). arXiv: 2409.11136 [cs.IR]. URL: <https://arxiv.org/abs/2409.11136>.